Minería de Datos
Grado en Ciberseguridad e Inteligencia Artificial

Proyecto Individual

Análisis de un Barómetro Social

Entregable 1

Ingesta, EDA y Definición del Problema

Estudio: Barómetro Social — CIS Estudio 1162
Título: Constitución y Elecciones (I)
Alumno: Esteban Sánchez Gámez
Entrega: Entrega 1 (25 %)

Índice

1. Comprensión del Dataset **2**
1.1. Identificación del estudio . . . 2
1.2. Tipos de variables . . . 2
1.3. Codificación . . . 3

2. Análisis Exploratorio de Datos (EDA) **4**
2.1. Valores faltantes . . . 4
2.2. Distribuciones de variables clave . . . 5
2.2.1. Variable P20 — Edad . . . 5
2.2.2. Variable P18 — Sexo . . . 6
2.2.3. Variable P19 — Estado Civil . . . 6
2.2.4. Variable P21 — Nivel de estudios . . . 6
2.2.5. Variable P1 — Definición de la Constitución . . . 7
2.2.6. Variables P15 / P16 — Voto y posición ante la Constitución . . . 7
2.2.7. Variable P25 — Partido político votado . . . 8
2.3. Detección de outliers . . . 8
2.4. Relaciones entre variables . . . 9
2.4.1. P15 (Voto) vs. P18 (Sexo) . . . 9
2.4.2. P16 (Posición) vs. P21 (Estudios) . . . 9
2.4.3. P24 (Ingresos) vs. P25 (Partido) . . . 10

3. Problemas Identificados en el Dataset **11**

4. Definición de Preguntas de Análisis **12**
4.1. Preguntas Business Intelligence (BI) . . . 12
4.2. Preguntas Business Analytics (BA) . . . 12
4.3. Preguntas Data Science (DS) . . . 13

1. Comprensión del Dataset

1.1. Identificación del estudio

El dataset utilizado corresponde al Estudio número 1162 del Centro de Investigaciones Sociológicas (CIS), titulado *Constitución y Elecciones (I)*. Este barómetro fue realizado en 1978 y recoge la opinión de la población española sobre el proyecto constitucional, en un momento histórico de especial relevancia: la transición a la democracia y la elaboración de la Constitución española.

Campo	Valor
Número de estudio	1162
Título	Constitución y Elecciones (I)
Universo	Población española de 18 años o más
Año	1978
N.º de registros	1.192 entrevistas
N.º de variables	81 variables

Cuadro 1: Ficha técnica del dataset

1.2. Tipos de variables

El dataset contiene 81 variables de los siguientes tipos:

Tipo	**Cantidad**	**Ejemplos**
Cadena (`str`) — Categórica	74	P1, P2, P18, P19, P21, P22, P23, P24, P25...
Entero (`int64`) — Numérica discreta	5	ESTU, CUES, T1, T2, P20 (edad)
Decimal (`float64`) — Numérica continua	2	N2, N3

Cuadro 2: Distribución de tipos de variables

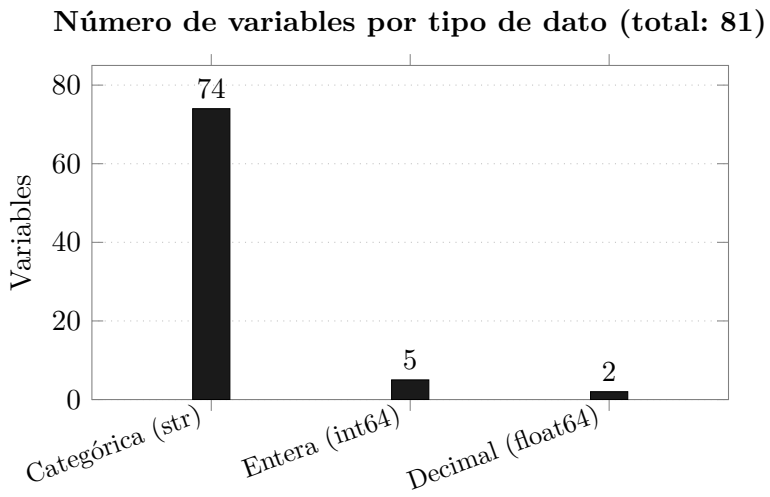

Figura 1: Distribución de variables por tipo de dato

La mayoría de variables son categóricas codificadas como texto. Se distinguen las siguientes categorías temáticas:

- **Variables administrativas:** ESTU, CUES, T1, T2, ENTREV.
- **Variables de opinión sobre la Constitución (P1–P16):** opiniones, medios de información consultados, valoraciones del proyecto.
- **Variables sociodemográficas (P17–P28):** sexo, edad, estado civil, estudios, ocupación, religión, ingresos, partido político y región.
- **Variables de escala numérica (P801–P807):** valoraciones en escala 1–7.
- **Variables de control geográfico (P27, P28, N4, N5):** región y tamaño de municipio.

1.3. Codificación

El libro de códigos (`codigo1162.pdf`) y el cuestionario (`cues1162.pdf`) permiten interpretar las variables:

- **P20 (Edad):** el libro de códigos sugiere rangos, pero el dataset contiene valores exactos (18–88 años). Se mantiene como numérica continua.
- **P24 (Ingresos):** contiene frases del tipo *"De 36.000 ptas a 45.000 ptas mensuales"*. Requiere recodificación ordinal (1–9).
- **P801–P807:** aparecen como cadenas de texto ('1', '2'. . . '7', 'N.S.', 'N.C.', 'No procede') aunque su naturaleza es numérica ordinal.
- **Valores NS/NC:** los valores 'No sabe', 'No contesta', 'N/S - N/C', 'N.S.', 'N.C.' deben tratarse como *missing values*.
- **'No procede':** indica que la pregunta no aplica al encuestado (diseño condicional del cuestionario).

2. Análisis Exploratorio de Datos (EDA)

2.1. Valores faltantes

Se han analizado los valores faltantes considerando tanto las celdas vacías (`NaN`) como los valores textuales que representan no-respuesta.

Particularidad estructural clave: aproximadamente el 50 % del dataset presenta 'No procede' en las preguntas P2–P16 y P801–P807. Esto se debe al **diseño condicional del cuestionario**: si el encuestado no sabe definir la Constitución (P1), el entrevistador salta directamente a las preguntas sociodemográficas. Por tanto, este patrón **no es una pérdida de datos**, sino un *missing* estructural que debe tratarse como tal, sin eliminar las filas afectadas.

Rango	Variables	Causa principal	Tratamiento
>90 %	P1208, P1209, P1210, P1211, P1202, P1207	NS/NC masivos + No procede	Evaluar eliminación
50–90 %	P2–P16, P801–P807, P1001, P13xx, P14xx	Diseño condicional de cuestionario	Missing estructural
15–50 %	P23A, P23B, N3, P22A, P25, P24	NS/NC + variables excluyentes	Missing value
1–15 %	N1, P22, N4, N5, P21, P17...	NS/NC puntual	Missing value
0 %	P18 (sexo), P20 (edad), P28 (municipio)	Variables completas	Ninguno

Cuadro 3: Resumen de valores faltantes por rango de porcentaje

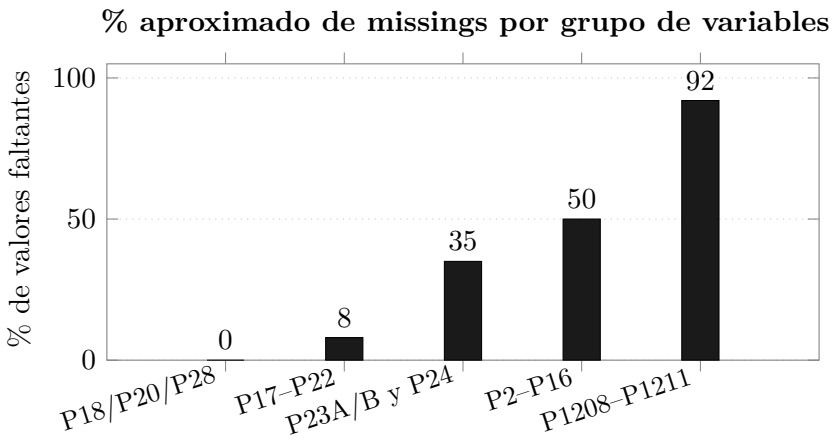

Figura 2: Porcentaje estimado de missings por grupo de variables

2.2. Distribuciones de variables clave

2.2.1. Variable P20 — Edad

La edad es la única variable numérica continua con información real del encuestado. No presenta valores faltantes.

N	Media	Desv. Típ.	Mínimo	Mediana	Máximo
1.192	44,3 años	16,5 años	18	43	88

Cuadro 4: Estadísticos descriptivos de P20 (Edad)

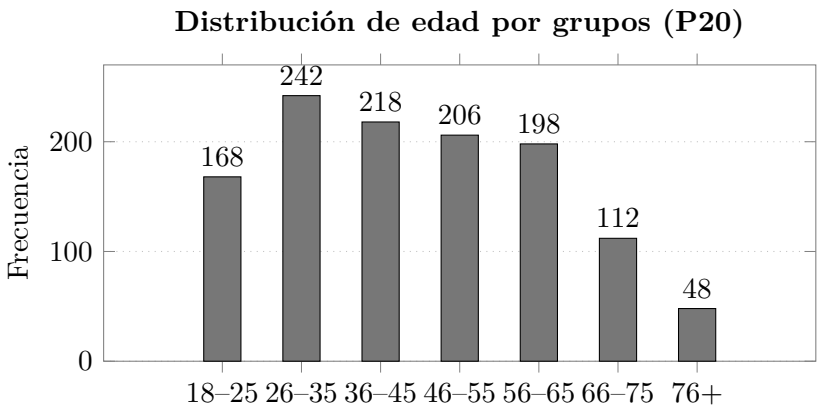

Figura 3: Distribución de edades agrupadas en intervalos (datos reales del dataset)

La distribución es aproximadamente normal con ligera asimetría positiva. La muestra cubre adecuadamente todos los grupos de edad adultos.

2.2.2. Variable P18 — Sexo

Categoría	Frecuencia	Porcentaje
Hombre	614	51,5 %
Mujer	578	48,5 %
Total	**1.192**	**100 %**

Cuadro 5: Distribución de P18 (Sexo)

2.2.3. Variable P19 — Estado Civil

Estado civil	Frecuencia	Porcentaje
Casado/a	819	68,7 %
Soltero/a	262	22,0 %
Viudo/a	98	8,2 %
Divorciado/a o separado/a	8	0,7 %
NS/NC	1	0,1 %

Cuadro 6: Distribución de P19 (Estado civil)

2.2.4. Variable P21 — Nivel de estudios

La distribución refleja el perfil educativo de la España de 1978: fuerte predominancia de bajo nivel educativo.

Nivel de estudios	N	%
Menos de primarios, sabe leer	491	41,2
Estudios primarios completos	265	22,2
Menos de primarios, no sabe leer	98	8,2
Bachiller superior	83	7,0
Universitario o grado superior	72	6,0
Grado medio	71	6,0
Bachiller elemental	69	5,8
Formación profesional	25	2,1

Cuadro 7: Distribución de P21 (Nivel de estudios)

2.2.5. Variable P1 — Definición de la Constitución

Esta variable mide la comprensión del concepto 'Constitución'. Aproximadamente el 50 % de los encuestados la define correctamente.

Definición elegida	N	%
Conjunto de principios que regulan la vida del Estado *(CORRECTA)*	592	49,7
Ordenanzas que regulan la Administración	258	21,6
Documento para arreglar problemas económicos	250	21,0
Concierto que tipifica delitos y penas	86	7,2

Cuadro 8: Distribución de P1 (Definición de la Constitución)

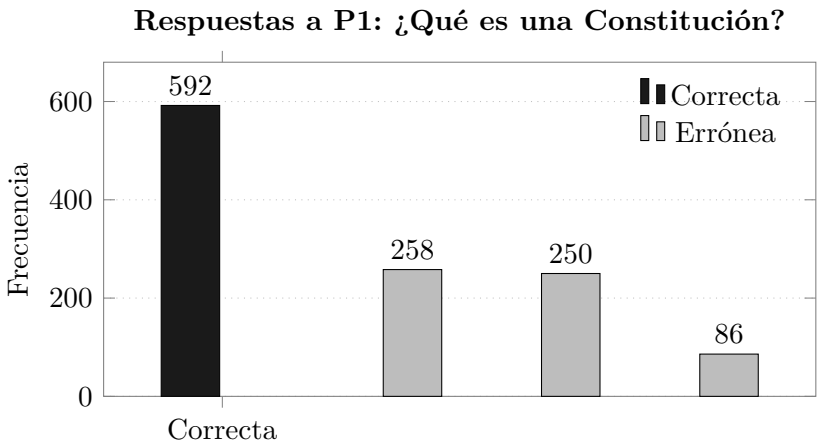

Figura 4: Distribución de respuestas a P1 (comprensión de la Constitución)

2.2.6. Variables P15 / P16 — Voto y posición ante la Constitución

P15 recoge si el encuestado votó en el referéndum y P16 su posición actual. Ambas presentan ∼50 % de 'No procede' por el filtro de P1.

P15 — Voto en referéndum			P16 — Posición actual*	
Respuesta	N	%	Respuesta	N
Sí (votó a favor)	483	40,5	A favor	331
No (votó en contra)	56	4,7	En contra	17
NS/NC	50	4,2	Se abstendrá	10
No procede	600	50,3	NS/NC	125

Cuadro 9: Distribución de P15 y P16. *Solo entre quienes respondieron correctamente P1.

2.2.7. Variable P25 — Partido político votado

Partido	N	%
U.C.D. (Unión de Centro Democrático)	296	24,8
P.S.O.E.	256	21,5
No votó	233	19,5
No contesta	207	17,4
P.C.E.	54	4,5
Otros	49	4,1
A.P. (Alianza Popular)	32	2,7
P.S.P., P.N.V., D.C., otros menores	61	5,1

Cuadro 10: Distribución de P25 (partido político votado)

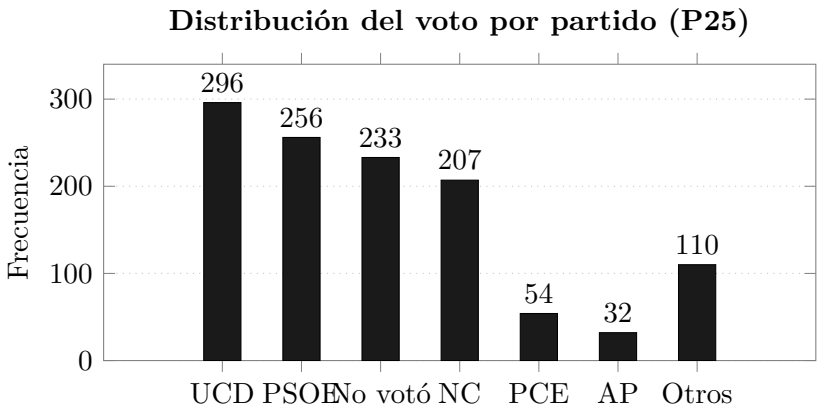

Figura 5: Distribución del voto por partido político (P25)

2.3. Detección de outliers

Se ha aplicado el método IQR (*Rango Intercuartílico*) para la única variable numérica continua con datos reales: P20 (Edad).

Q1 (25 %)	Q3 (75 %)	IQR
30 años	57 años	27 años

Cuadro 11: Cálculo IQR para P20 (Edad)

- Límite inferior: $30 - 1{,}5 \times 27 = -10{,}5$ (no aplica; mínimo real = 18).
- Límite superior: $57 + 1{,}5 \times 27 = 97{,}5$. El valor máximo es 88 $\rightarrow$ dentro del rango.
- **Conclusión: no se detectan outliers estadísticos en la edad.**

Para las variables categóricas de escala (P801–P807, valores 1–7) no existen outliers por definición, al tratarse de escalas cerradas. Las variables de ingresos (P24) y partido (P25) tampoco presentan valores anómalos más allá del esperado NS/NC.

2.4. Relaciones entre variables

2.4.1. P15 (Voto) vs. P18 (Sexo)

Voto	Hombre	Mujer	Total
Sí (votó a favor)	287 (46,7 %)	196 (33,9 %)	483
No (votó en contra)	31	25	56
NS/NC	26	24	50
No procede	268	332	600

Cuadro 12: Tabla de contingencia P15 × P18

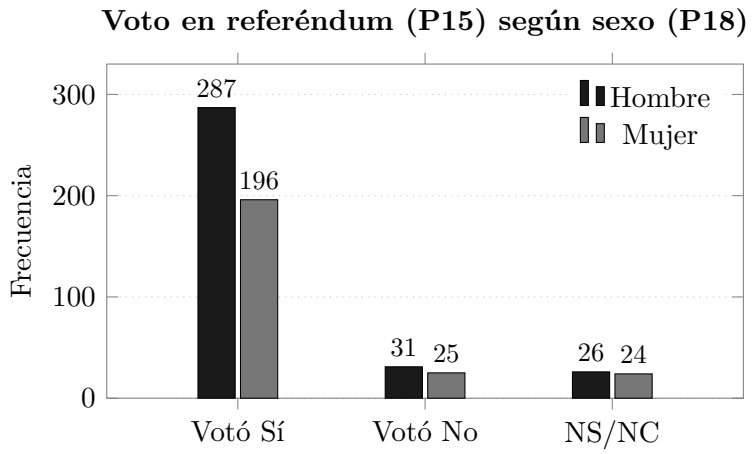

Figura 6: Participación en el referéndum constitucional según sexo

Los hombres mostraron mayor participación en el referéndum constitucional que las mujeres (46,7 % vs. 33,9 %). Esto puede relacionarse con diferencias de nivel educativo y acceso a información política en la España de 1978.

2.4.2. P16 (Posición) vs. P21 (Estudios)

El cruce entre posición ante la Constitución y nivel educativo muestra una tendencia clara: a mayor nivel de estudios, mayor proporción de encuestados favorables y menor proporción de NS/NC. Los universitarios expresan opinión en mayor medida que quienes no saben leer.

2.4.3. P24 (Ingresos) vs. P25 (Partido)

Los votantes de UCD presentan una distribución de ingresos más favorable que los del PCE. Los votantes del PSOE se concentran en tramos medios. Este patrón es coherente con la sociología electoral de la España de 1978.

3. Problemas Identificados en el Dataset

Variable	Problema	Decisión	Justificación
ESTU, CUES, T1, T2, ENTREV	Variables administrativas sin valor analítico	Eliminar del dataset	No aportan información sociológica. ENTREV = 'Anonimizado' en todas las filas.
P20 (Edad)	Libro de códigos indica rangos; el CSV contiene valores exactos	Mantener como numérica continua (`integer`)	Los valores exactos permiten calcular medias y desviaciones con mayor precisión.
P24 (Ingresos)	Mezcla de texto descriptivo y NS/NC	Recodificar a escala ordinal 1–9	Necesario para tratamiento matemático. NS/NC → missing.
P23A / P23B (Ocupación)	Variables excluyentes con masivos valores '0' (no procede)	Tratar '0' y '99' como missing values	Eliminar filas vaciaría casi todo el dataset. La imputación falsearía la ocupación real.
P1–P16, P801–P807	Valores '8' y '9' codifican NS/NC mezclados con respuestas reales	Cambiar 8 y 9 a missing values	Un '9' (No contesta) no es una puntuación alta; distorsionaría la media de opinión.
'No procede' en P2–P16	∼50 % del dataset tiene 'No procede' por diseño condicional	Tratar como missing estructural, NO eliminar filas	Perder esas filas eliminaría la mitad de la muestra. Estas personas tienen datos sociodemográficos válidos.
P801–P807	Escala numérica guardada como texto	Convertir a numérico	Necesario para estadísticos descriptivos e incorporación en modelos.

Cuadro 13: Resumen de problemas detectados y decisiones tomadas

4. Definición de Preguntas de Análisis

4.1. Preguntas Business Intelligence (BI)

#	Pregunta	Variables
BI-1	**¿Cuál era la distribución del voto en el referéndum constitucional de 1978 según el sexo y el nivel de estudios del encuestado?** *Justificación: permite caracterizar el perfil del votante constitucional, aspecto fundamental para entender la democracia española.*	P15, P18, P21
BI-2	**¿Qué porcentaje de la población española de 1978 sabía definir correctamente qué es una Constitución, y cómo varía ese porcentaje por región geográfica?** *Justificación: mide el nivel de conocimiento cívico. Relevante para contextualizar la transición.*	P1, P27, P28

Cuadro 14: Preguntas Business Intelligence

4.2. Preguntas Business Analytics (BA)

#	Pregunta	Variables
BA-1	**¿Existe una relación entre el nivel de ingresos del encuestado y su posición (a favor/en contra) ante la Constitución de 1978?** *Justificación: permite analizar si el apoyo constitucional tenía un componente socioeconómico.*	P16, P24, P25
BA-2	**¿Qué factores sociodemográficos (edad, sexo, estudios, religiosidad) se asocian más con el nivel de información sobre la Constitución, medido por los medios que sigue el encuestado?** *Justificación: identifica los grupos más informados sobre el proceso constituyente. Relaciona el perfil demográfico con el consumo de medios (P2, P301, P302).*	P2, P301, P302, P18, P20, P21, P22

Cuadro 15: Preguntas Business Analytics

4.3. Preguntas Data Science (DS)

#	Pregunta
DS-1	**¿Es posible predecir si un encuestado votó 'Sí' en el referéndum constitucional a partir de su perfil sociodemográfico (edad, sexo, estudios, ocupación, ingresos, religión, región)?** *Justificación: clasificación binaria (Sí/No) bien definida. Variable target: P15. Features: variables sociodemográficas. El modelo se validará con división train/test y métricas de accuracy, precisión y recall.*
DS-2	**¿Es posible identificar grupos o perfiles de ciudadanos con actitudes similares hacia la Constitución mediante técnicas de clustering no supervisado?** *Justificación: aplicación no supervisada que no asume variable respuesta. Puede revelar segmentos ocultos (p.ej. 'informados a favor', 'desinformados indiferentes'). Se validará con el índice de silueta.*

Cuadro 16: Preguntas Data Science

Nota: El análisis, la interpretación de los datos y las decisiones metodológicas de este documento son trabajo mío. La maquetación en LaTeX la ha realizado Claude (Anthropic).