Minería de Datos
Grado en Ciberseguridad e Inteligencia Artificial

Proyecto Individual

Análisis de un Barómetro Social

Entregable 2

Preparación de Datos

Estudio: Barómetro Social — CIS Estudio 1162
Título: Constitución y Elecciones (I)
Alumno: Esteban Sánchez Gámez
Entrega: Entrega 2 (25 %)
Código: `github.com/Sauvageduck24/Univ`

Índice

1. Introducción y Estrategia de Preparación **2**

2. Limpieza de Datos **3**
2.1. Eliminación de variables administrativas 3
2.2. Verificación de duplicados 3

3. Tratamiento de Missing Values **4**
3.1. Tipología de valores faltantes identificados 4
3.2. Gestión de NS/NC 4
3.3. Gestión de "No procede" 5

4. Recodificación de Variables **6**
4.1. P24 — Ingresos familiares (texto → escala ordinal 1–9) 6
4.2. P801–P807 — Escalas de valoración (texto → numérico) 7
4.3. P22 — Religiosidad (verificación) 7
4.4. P23A y P23B — Ocupación (tratamiento de "No procede") 8

5. Transformación de Variables **9**
5.1. Discretización: P20 → P20_grupo (edad en intervalos) 9
5.2. Creación de variable: P15_bin (target para DS-1) 9
5.3. Selección de variables para cada análisis 11

6. Construcción del Dataset Analítico Final **12**
6.1. Dataset completo limpio (base para BI y BA) 12
6.2. Dataset analítico DS-1 (clasificación) 12
6.3. Dataset analítico DS-2 (clustering) 13

7. Resumen de Decisiones de Preparación **14**

1. Introducción y Estrategia de Preparación

Entregable 2, encargado de transformar el dataset bruto del Estudio CIS 1162 en un dataset limpio y coherente justificado para los análisis BI, BA y DS del Entregable 1.

La limpieza del dataset la voy a realizar con Python. Aunque en clase hemos trabajado principalmente con Altair AI Studio, considero que Python es una opción más adecuada porque permite realizar el proceso de forma más rápida, reproducible y flexible. Además, para el siguiente entregable (entregable 3), centrado en modelos, facilitará continuar el trabajo de manera más eficiente manteniendo resultados consistentes. Todo el código empleado está disponible en el repositorio público: `github.com/Sauvageduck24/Univ/mineria_de_datos`.

Dimensión	Estado inicial
Registros	1.192 entrevistas
Variables	81 columnas
Tipo mayoritario	Cadena de texto (`str`) — 74 variables
Principal problema	∼50 % de *missings* estructurales (diseño condicional)
Variables a eliminar	4 administrativas sin valor analítico
Variables a recodificar	P24 (ingresos), P801–P807 (escala texto), P15 (target binario)

Cuadro 1: Estado inicial del dataset antes de la preparación

La estrategia general son cinco fases:

1. **Eliminación** de variables administrativas y sin contenido analítico.
2. **Tratamiento** de valores NS/NC y 'No procede' como *missing values*.
3. **Recodificación** de variables categóricas con contenido ordinal o numérico.
4. **Transformación** mediante discretización de variables continuas y creación de nuevas variables derivadas.
5. **Construcción** del dataset analítico final por análisis (BI, BA, DS).

2. Limpieza de Datos

2.1. Eliminación de variables administrativas

El dataset original incluye 4 variables que no aportan información sociológica: son identificadores internos de la encuesta o valores constantes. Se eliminan antes de cualquier análisis.

Variable	Contenido	Justificación de eliminación
`ESTU`	Número de estudio (constante: 1162)	Valor idéntico en todas las filas. No discrimina.
`T1`	Tipo de encuesta (constante: 1)	Valor idéntico en todas las filas.
`T2`	Subtipo (constante: 2)	Valor idéntico en todas las filas.
`ENTREV`	Identificador del entrevistador	Valor 'Anonimizado' en las 1.192 filas. No aporta información.

Cuadro 2: Variables administrativas eliminadas del dataset

Nota: La variable `CUES` (número de cuestionario) se mantiene como identificador único de fila, aunque no se usará como *feature* en ningún modelo. Su presencia permite trazabilidad entre el dataset analítico y el original.

Tras esta eliminación el dataset queda en **77 variables** (1.192 registros).

2.2. Verificación de duplicados

Se comprueba la unicidad de registros usando `CUES` como clave primaria. El análisis confirma que los 1.192 valores de `CUES` son únicos: **no hay filas duplicadas** en el dataset.

3. Tratamiento de Missing Values

3.1. Tipología de valores faltantes identificados

El dataset presenta tres tipos distintos de ausencia de dato, cada uno con tratamiento diferente:

Tipo	Valores en el dataset	Tratamiento
Missing real (`NaN`)	Celda vacía en el Excel	Ya es `NaN` en pandas; no requiere transformación adicional.
NS/NC textual	'NS/NC', 'N/S - N/C', 'N.S.', 'N.C.', 'No sabe', 'No contesta', 'N/C'	Reemplazar por `NaN`. Son no-respuestas, no valores informativos.
Missing estructural	'No procede'	Reemplazar por `NaN`. Indica que la pregunta no aplica al encuestado por diseño condicional del cuestionario. Las filas afectadas **no se eliminan**.

Cuadro 3: Tipología de valores faltantes y decisión de tratamiento

3.2. Gestión de NS/NC

Los valores NS/NC son respuestas de no-sabe o no-contesta que no pueden usarse como categoría en ningún modelo ni estadístico descriptivo sin sesgar los resultados. Su tratamiento como `NaN` permite que pandas los excluya automáticamente de los cálculos sin necesidad de eliminar filas.

Las variables más afectadas por NS/NC puro (excluyendo 'No procede') son:

Variable	NS/NC (N)	NS/NC (%)
P806 (Valoración Constitución — escala 6)	245	20,6
P807 (Valoración Constitución — escala 7)	188	15,8
P805 (Valoración Constitución — escala 5)	205	17,2
P24 (Ingresos familiares)	212	17,8
P25 (Partido político)	8	0,7
P15 (Voto en referéndum)	50	4,2
P22 (Religiosidad)	27	2,3

Cuadro 4: Principales variables con NS/NC

3.3. Gestión de "No procede"

Como se explicó en el Entregable 1, el 'No procede' es un **missing estructural por diseño**: si el encuestado no sabe definir la Constitución (P1), el cuestionario salta directamente a las preguntas sociodemográficas (P17–P28), dejando sin respuesta todas las preguntas P2–P16 y P801–P807.

Las 600 filas con 'No procede' en P2–P16 no se eliminan. Estas personas tienen datos sociodemográficos completos (edad, sexo, estudios, ocupación, ingresos, partido, región) que son válidos y necesarios para los análisis BA y DS.

Grupo de variables	No procede (N)	No procede (%)
P2–P16 (preguntas sobre la Constitución)	600	50,3
P801–P807 (escalas de valoración)	600	50,3
P23A (ocupación asalariado)	374	31,4
P23B (ocupación autónomo)	887	74,4

Cuadro 5: Variables afectadas por missing estructural "No procede"

4. Recodificación de Variables

4.1. P24 — Ingresos familiares (texto → escala ordinal 1–9)

La variable P24 contiene frases descriptivas de tramos salariales en pesetas. Para poder utilizarla en análisis cuantitativos (correlaciones, modelos) se recodifica a una escala ordinal de 1 a 9, donde 1 representa el tramo más bajo y 9 el más alto. Los NS/NC se convierten en `NaN`.

Código	Categoría original	N	%
1	Hasta 6.000 ptas mensuales	21	2,2
2	De 6.000 ptas a 11.000 ptas mensuales	60	6,2
3	De 12.000 ptas a 18.000 ptas mensuales	156	16,1
4	De 19.000 ptas a 25.000 ptas mensuales	204	21,1
5	De 26.000 ptas a 35.000 ptas mensuales	206	21,3
6	De 36.000 ptas a 45.000 ptas mensuales	155	16,0
7	De 46.000 ptas a 65.000 ptas mensuales	111	11,5
8	De 66.000 ptas a 85.000 ptas mensuales	30	3,1
9	Más de 85.000 ptas mensuales	37	3,8
`NaN`	NS/NC	212	—

Cuadro 6: Recodificación de P24 a escala ordinal P24_num (N válido = 980)

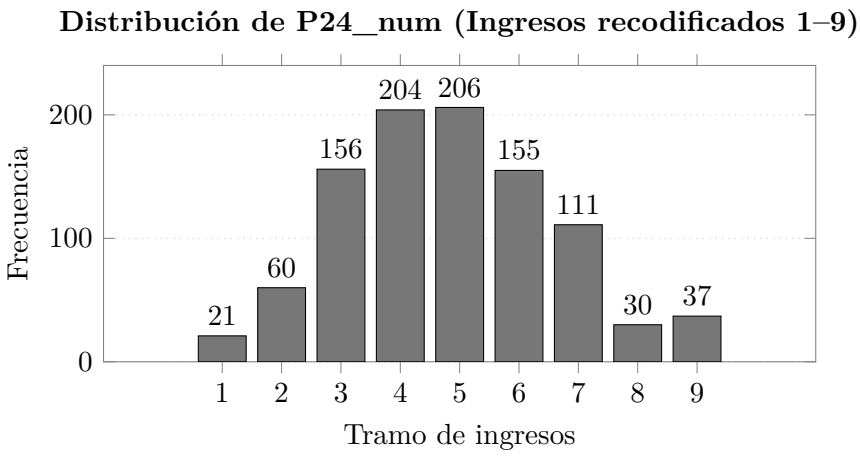

Figura 1: Distribución de ingresos tras recodificación (excluidos 212 NS/NC)

La distribución sigue una forma aproximadamente normal centrada en los tramos 4–5 (ingresos medios de 19.000–35.000 ptas mensuales), coherente con el perfil socioeconómico de la España de 1978.

4.2. P801–P807 — Escalas de valoración (texto → numérico)

Las variables P801–P807 recogen valoraciones en escala 1–7 del proyecto constitucional, pero están almacenadas como cadenas de texto en el Excel original. Se convierten a tipo numérico (`float64`), asignando `NaN` a 'N.S.', 'N.C.' y 'No procede'.

Variable	N válido	NS/NC (N)	Media	Desv. Típ.
P801 (Democracia / orden)	468	120	2,74	1,82
P802 (Familia / trabajo)	488	99	4,57	1,85
P803 (Seguridad social / iniciativa privada)	489	99	5,02	1,69
P804 (Laicidad / religión)	473	115	3,59	1,79
P805 (Centralización / autonomía)	381	205	3,01	1,84
P806 (Cambio social / conservadurismo)	338	245	2,91	1,65
P807 (Izquierda / derecha)	395	188	3,17	1,91

Cuadro 7: Estadísticos de P801–P807 tras conversión a numérico

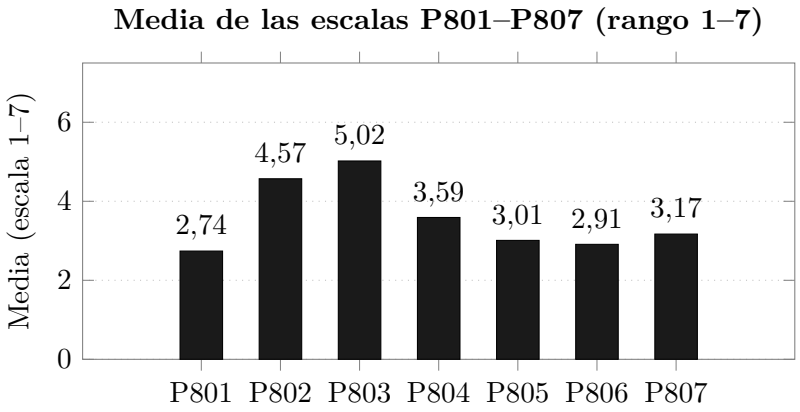

Figura 2: Medias de las escalas de valoración P801–P807

P803 (Seguridad social frente a iniciativa privada) obtiene la media más alta (5,02), lo que indica una ligera tendencia de los encuestados hacia posiciones más favorables al Estado de bienestar. P801 (Democracia frente a orden) tiene la media más baja (2,74), reflejando cierta preferencia por la democracia en el contexto de la Transición.

4.3. P22 — Religiosidad (verificación)

P22 ya está correctamente codificada como variable categórica. Se verifica que los valores 'N/C' se traten como NS/NC. La distribución es coherente con el perfil religioso de la España de 1978.

Categoría	N	%
Católico practicante	613	51,4
Católico no practicante	367	30,8
No creyente	90	7,5
Indiferente	79	6,6
Otras religiones	11	0,9
N/C → `NaN`	27	2,3

Cuadro 8: Distribución de P22 (Religiosidad) tras tratamiento de N/C

4.4. P23A y P23B — Ocupación (tratamiento de "No procede")

P23A recoge la ocupación de asalariados y P23B la de autónomos: son mutuamente excluyentes por diseño del cuestionario. El valor 'No procede' no indica desempleo sino que la persona pertenece a la categoría opuesta.

Variable	Descripción	N válido	N procede → NaN
P23A	Ocupación del asalariado	792 (66,4 %)	374
P23B	Ocupación del autónomo	291 (24,4 %)	887

Cuadro 9: Tratamiento de P23A y P23B

No se crea una variable de ocupación unificada porque las categorías de P23A (asalariados: obreros, funcionarios...) y P23B (autónomos: industriales, agricultores...) no son comparables directamente sin un esquema de equivalencia externo (e.g. CNO-94). Ambas se mantienen como variables separadas y se usan como features en los modelos con cautela.

5. Transformación de Variables

5.1. Discretización: P20 → P20_grupo (edad en intervalos)

La edad (P20) es una variable numérica continua. Para los análisis BI y BA se crea una versión discretizada **P20_grupo** que agrupa los valores en 7 intervalos. Esto facilita la visualización de distribuciones por cohorte y la comparación de perfiles entre grupos de edad.

La variable original P20 se conserva para los modelos DS, donde la edad como valor numérico tiene mayor poder predictivo que su versión discretizada.

P20_grupo	Frecuencia	Porcentaje
18–25 años	196	16,4
26–35 años	214	17,9
36–45 años	234	19,6
46–55 años	224	18,8
56–65 años	171	14,3
66–75 años	121	10,2
76+ años	32	2,7

Cuadro 10: Distribución de P20_grupo (variable de edad discretizada)

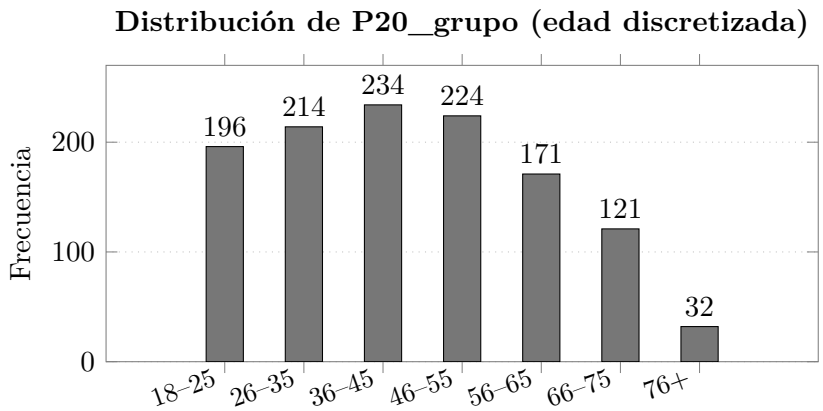

Figura 3: Distribución de grupos de edad tras discretización de P20

5.2. Creación de variable: P15_bin (target para DS-1)

La pregunta DS-1 plantea predecir si un encuestado votó 'Sí' en el referéndum constitucional. Para ello se crea la variable binaria **P15_bin** a partir de P15:

- `P15 = 'Sí'` → **P15_bin = 1**

- `P15 = 'No'` → **P15_bin = 0**
- `P15 = 'No procede'` o `'N/S - N/C'` → **`NaN`** (excluido del dataset de entrenamiento)

P15_bin	N	% (sobre válidos)
1 — Votó Sí	483	89,6
0 — Votó No	56	10,4
Total válido	**539**	**100 %**
`NaN` (No procede + NS/NC)	653	—

Cuadro 11: Distribución de P15_bin — variable target para DS-1

El dataset de entrenamiento para DS-1 presenta un fuerte desequilibrio: el 89,6 % de los casos válidos son 'Sí'. Esto implica que en el Entregable 3 se deberá considerar el uso de técnicas de balanceo (SMOTE, ajuste de pesos en el clasificador) o métricas insensibles al desequilibrio (F1-score, AUC-ROC) para evaluar correctamente el modelo.

5.3. Selección de variables para cada análisis

No todas las 77 variables son relevantes para los seis análisis definidos. A continuación se especifica el subconjunto de variables seleccionado para cada pregunta.

Análisi	Variables seleccionadas	Justificación
BI-1	P15, P18, P21, P20_grupo	Voto en referéndum cruzado con sexo, estudios y grupo de edad.
BI-2	P1, P27, P28	Comprensión de la Constitución por región y municipio.
BA-1	P16, P24_num, P25	Posición actual ante la Constitución frente a ingresos y partido.
BA-2	P2, P301, P302, P18, P20, P21, P22	Seguimiento de medios de comunicación por perfil sociodemográfico.
DS-1	P15_bin (target), P18, P20, P21, P22, P23A, P23B, P24_num, P25, P27, P28	Clasificación binaria del voto. Features sociodemográficas completas.
DS-2	P801–P807 (num), P16, P24_num, P25, P18, P20, P21	Clustering de actitudes constitucionales con perfil demográfico.

Cuadro 12: Selección de variables por análisis

6. Construcción del Dataset Analítico Final

6.1. Dataset completo limpio (base para BI y BA)

El dataset base, aplicadas todas las transformaciones anteriores, queda con la siguiente estructura:

Dimensión	Valor
Registros	1.192 (sin eliminación de filas)
Variables tras limpieza	77 (−4 administrativas)
Variables nuevas creadas	P24_num, P20_grupo, P15_bin (3 adicionales)
Variables P801–P807	Convertidas de texto a `float64`
Missing tratados	NS/NC y 'No procede' → `NaN`
Duplicados	0

Cuadro 13: Características del dataset analítico base

6.2. Dataset analítico DS-1 (clasificación)

El subconjunto para la pregunta DS-1 requiere que la variable target (P15_bin) sea no nula. Se aplica filtro `dropna(subset=['P15_bin'])`.

Variable	N válido	Missing (%)
P18 (Sexo)	539	0,0
P20 (Edad)	539	0,0
P21 (Estudios)	533	1,1
P22 (Religiosidad)	538	0,2
P23A (Ocup. asalariado)	523	3,0
P23B (Ocup. autónomo)	532	1,3
P24_num (Ingresos)	453	16,0
P25 (Partido)	535	0,7
P27 (Región)	539	0,0
P28 (Municipio)	539	0,0
P15_bin (target)	**539**	**0,0**

Cuadro 14: Dataset DS-1 — 539 registros con target no nulo

6.3. Dataset analítico DS-2 (clustering)

Para el clustering de actitudes (DS-2) se requiere que al menos las escalas P801–P807 sean válidas, lo que restringe la muestra a los 592 encuestados que respondieron correctamente P1 (los que saben definir la Constitución). Dentro de este grupo, la disponibilidad de todas las escalas es variable según el NS/NC en cada elemento.

Criterio de filtro	N resultante	% del total
Total dataset	1.192	100,0
P1 correcta (P2–P807 válidos)	592	49,7
P801 no nula	468	39,3
P801–P807 todas no nulas	277	23,2

Cuadro 15: Reducción de muestra para DS-2 según criterio de filtro

Dado que exigir las 7 escalas completas reduciría la muestra a 277 registros (23,2 %), en el Entregable 3 se considerará usar imputación por la mediana en las escalas con alta tasa de NS/NC (P805, P806, P807) para retener la mayor parte de los 592 encuestados activos.

7. Resumen de Decisiones de Preparación

Variable	Problema	Decisión	Justificación
ESTU, T1, T2, ENTREV	Variables administrativas / constantes	**Eliminar** (4 variables)	Cero valor analítico. Valor único o fijo en todas las filas.
Todos los NS/NC textuales	No-respuesta codificada como texto ('NS/NC', 'N.S.', 'N.C.'...)	Reemplazar por `NaN`	Tratarlos como categoría distorsionaría medias y modelos.
'No procede' (P2–P16, P801–P807, P23A/B)	*Missing* estructural por diseño condicional	Reemplazar por `NaN`; **no eliminar filas**	Las filas con 'No procede' contienen datos sociodemográficos válidos. Eliminarlas reduciría el dataset a la mitad.
P24 (Ingresos)	Texto descriptivo de tramos salariales	Recodificar a escala ordinal **P24_num** (1–9)	Necesario para tratamiento matemático. NS/NC → `NaN`.
P801–P807 (Escalas)	Escala 1–7 guardada como texto	Convertir a `float64` (**P80x_num**)	Necesario para calcular medias, desviaciones y aplicar clustering.
P20 (Edad)	Variable continua, difícil de visualizar por cohortes	Crear **P20_grupo** (7 intervalos)	Facilita análisis BI por cohorte. P20 original se conserva para modelos.
P15 (Voto referéndum)	Variable categórica ('Sí'/'No'/'No procede'/NS/NC)	Crear **P15_bin** = 1/0; resto → `NaN`	Variable target para DS-1. Necesita formato binario.
P23A / P23B (Ocupación)	Excluyentes por diseño; 'No procede' no es desempleo	'No procede' → `NaN`; **mantener ambas** como variables separadas	Combinarlas requeriría un esquema de equivalencia externo (CNO).

Cuadro 16: Tabla resumen de decisiones de preparación de datos

Nota: El análisis, la interpretación de los datos y las decisiones metodológicas de este documento son trabajo mío. La maquetación en LaTeX la ha realizado Claude (Anthropic).